邓柳英

教育背景

2020.09-2024.07　　同济大学　　交通工程 | 本科

- 主修课程：数据分析、项目管理、道路规划与几何设计、国土空间规划、运筹学

2024.09-2027.07　　同济大学　　交通运输 | 硕士研究生

- 研究方向：计算机视觉（路面病害检测）、三维重构（多视图几何）

技术栈

类别	具体技能内容
编程语言	Python（熟练）、R（熟练）、MATLAB（基础）
深度学习与计算机视觉	目标检测：MMdetection；多目标跟踪：Bytetrack、DeepSORT；特征提取：CNN；
机器学习与建模	XGBoost、LightGBM、Random Forest；支持多变量回归与时序预测
数据处理与分析	pandas、NumPy；R（dplyr、ggplot2）、MySQL；数据清洗、特征工程、可视化
模型部署与推理优化	ONNX 模型转换与推理；昇腾 NPU 部署（CANN）；模型量化与推理加速；边缘设备适配
工程能力	Linux 环境开发与调试、模型部署流程

1 全国大学生交通科技运输大赛

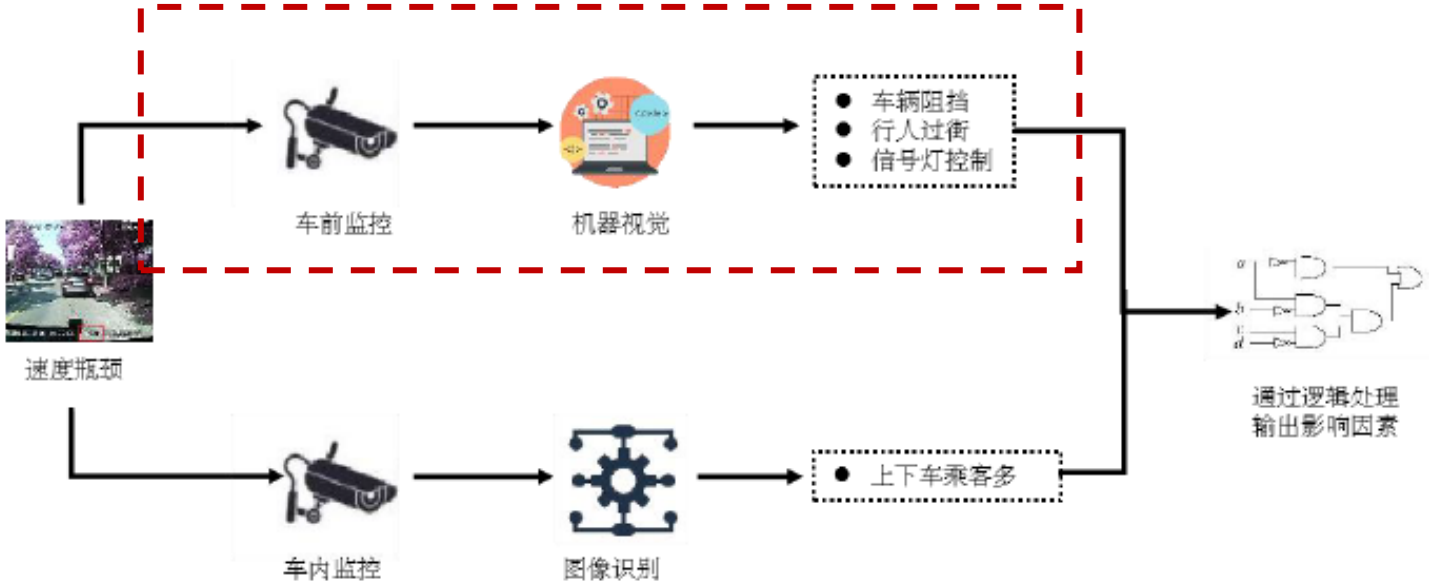

- 基于YOLOv5实现目标检测（车辆、行人、信号灯）
- 结合DeepSORT算法实现多目标追踪
- 基于摄像头内参（焦距、传感器尺寸）与图像像素坐标，建立像素距离→实际距离的映射关系，结合阈值判断

FineBI (帆软)

2 病害检测课程作业——数据特点

47,420 images

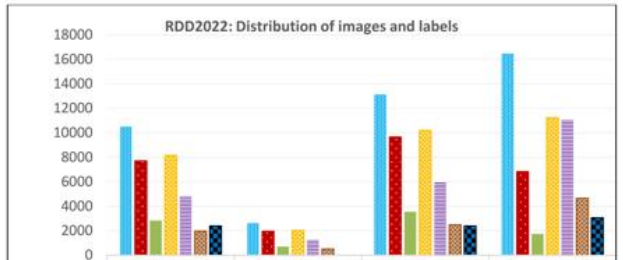

	#train_images	#test_images	#total_images	#train_labels
Japan	10506	2627	13133	16470
India	7706	1959	9665	6831
Czech	2829	709	3538	1745
Norway	8161	2040	10201	11229
US	4805	1200	6005	11014
China_M	1977	500	2477	4650
China_D	2401	0	2401	3068

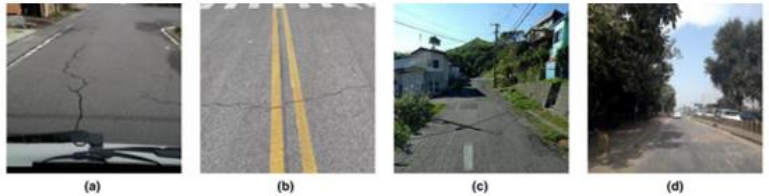

Norway数据集格式与内容说明

- **包含 8161 张图像，无标注样本共5247张**
- 分辨率：大多数图像分辨率为 3650 × 2044
- 原始标注格式：Pascal VOC（XML）
- 标注信息：类别、边界框坐标、图像 ID 等

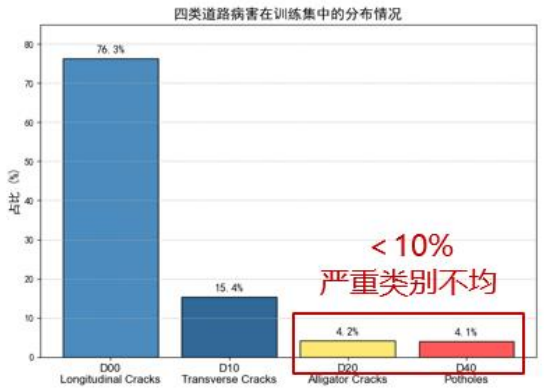

面积占比区间	目标数量	占总比例
0~0.05%	2173	19.35%
0.05%~0.1%	1355	12.07%
0.1%~0.5%	3649	32.50%
0.5%~1%	1528	13.61%
1%~2%	1180	10.51%
2%~5%	1025	9.13%
5%~10%	294	2.62%
10%~100%	25	0.22%

病害分布特征：

- **类别分布不均**
- **目标尺度多样**

带来的挑战：

- **小目标和稀有类别容易被漏检，检测精度受限**
- **对模型提出更高的泛化能力要求**

2 病害检测课程作业——模型对比分析

训练损失曲线（左：YOLOv8，右：RT-DETR）

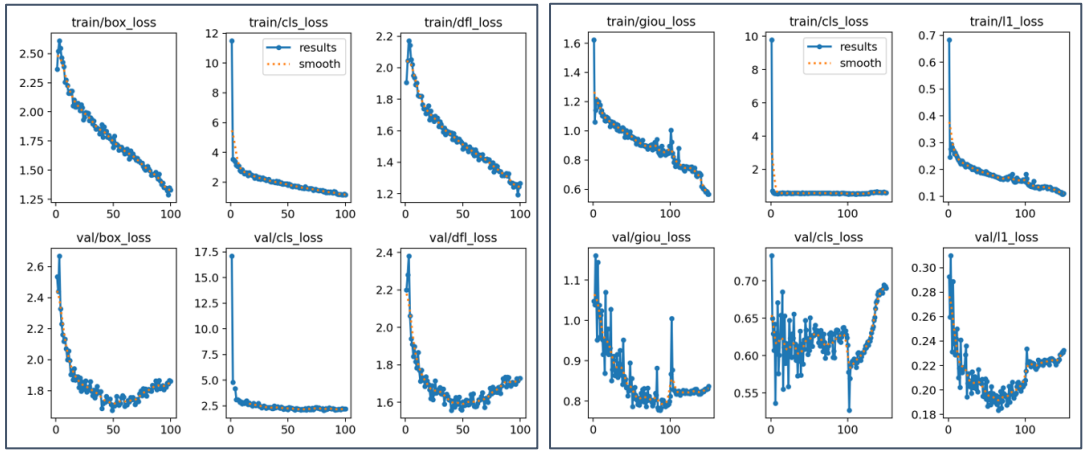

训练效率与稳定性

- YOLOv8损失曲线更为平滑，训练稳定
- DETR 验证阶段的损失波动较大，泛化能力有限

训练效率与稳定性

- RT-DETR 在所有关键精度指标上全面优于 YOLOv8
- RT-DETR 的类别识别能力普遍优于 YOLOv8，尤其在多类别之间的区分上更为准确。

Model	Precision	Recall	F1-Score	mAP@0.50	mAP@0.50:0.95
YOLOv8	0.281	0.306	0.30	0.320	0.133
RT-DETR	0.374	0.310	0.40	0.355	0.143

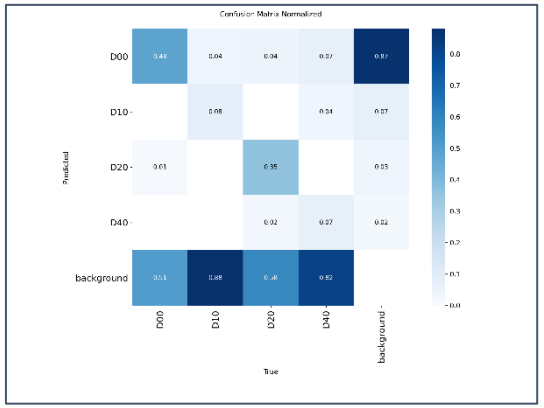

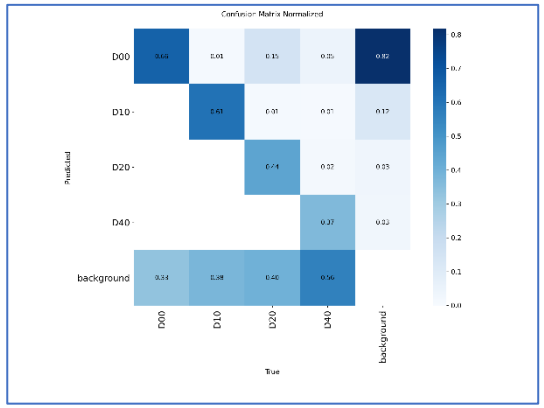

YOLOv8轻量化设计降低计算复杂度的同时也提高了模型的收敛效率和可控性，更适合快速、高效的收敛训练场景，DETR借助 Transformer 架构展现了更强的全局建模能力，更适合应用于对检测质量有较高要求的实际场景

2 病害检测课程作业——YOLOV8预测效果

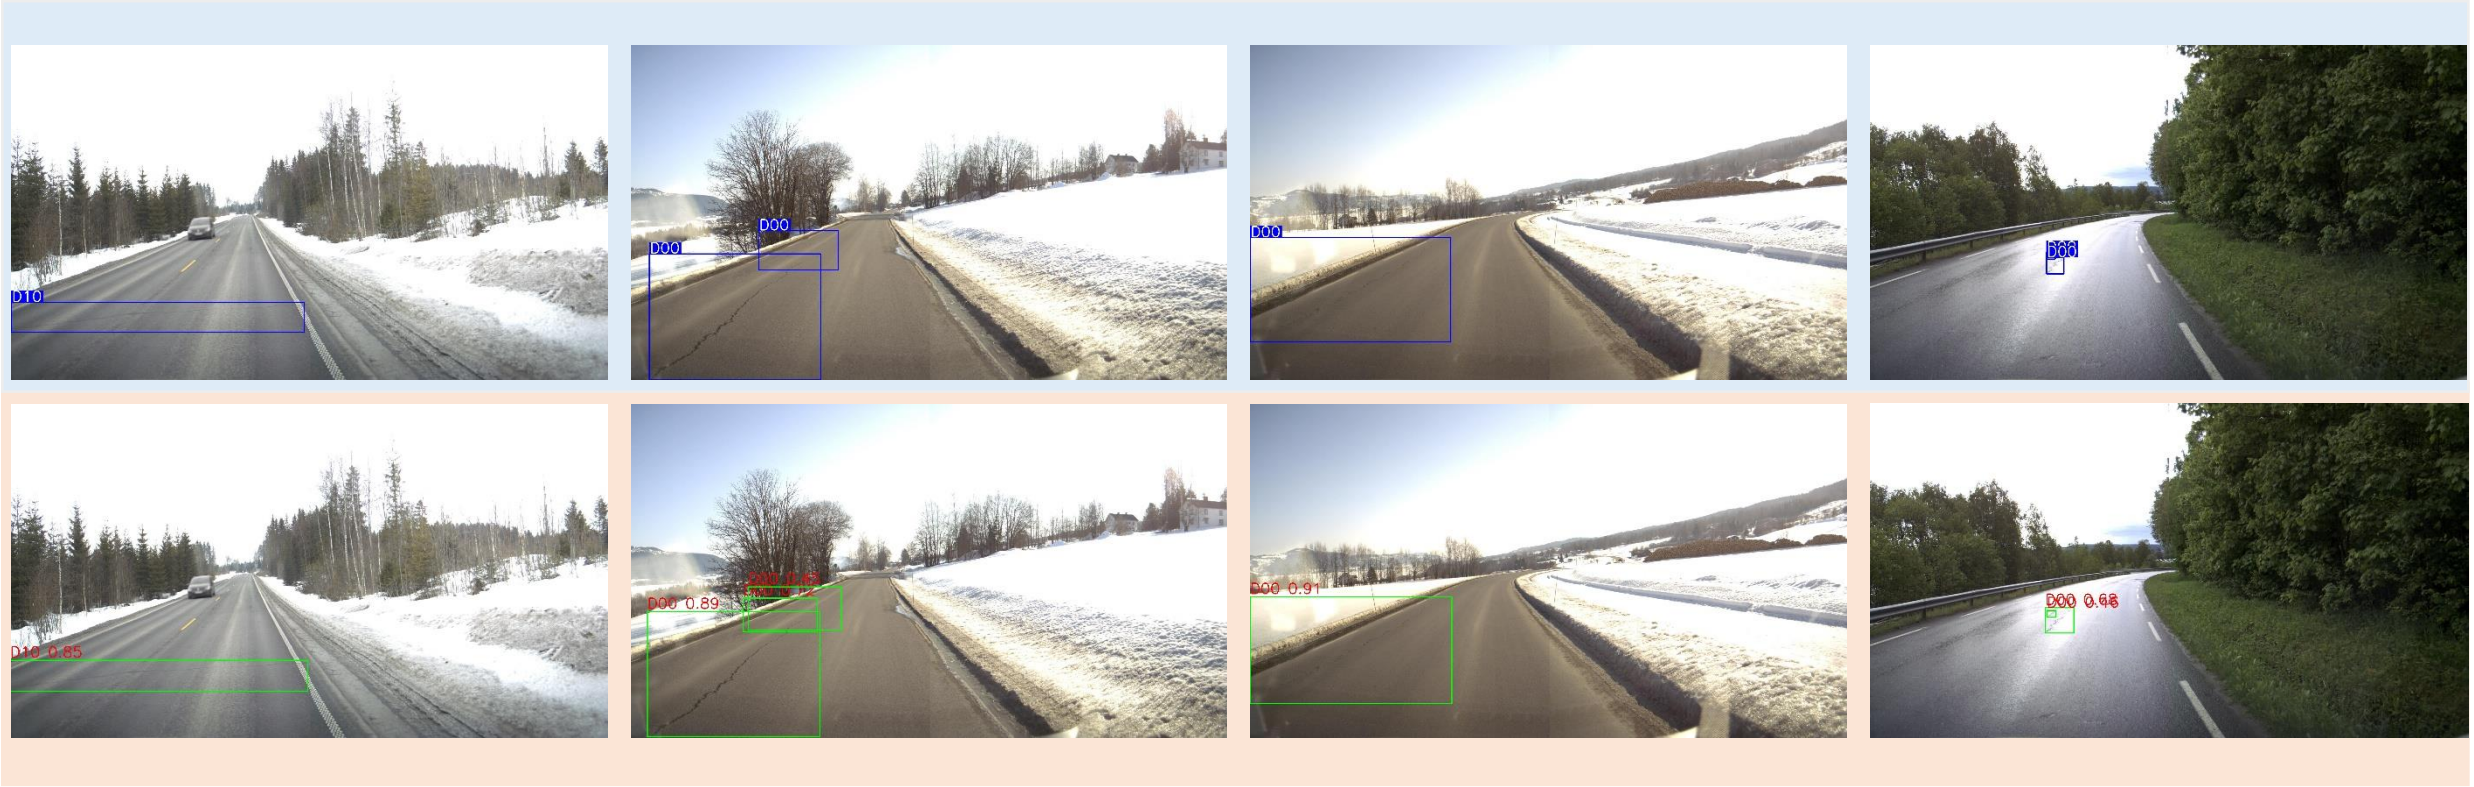

真实标注

预测结果

- 能较为准确地完成定位与分类任务
- 能识别较小较远的目标
- 具有一定抗反光能力

3 隧道交通感知——项目内容

委托工作内容	完成情况详情	状态
构建样本图像训练集	构建了包含 **5231** 张标注图像的专用数据集	**完成√**
识别算法准确性测试与升级	YOLOX：**91.8%** DINO：**96.5%** YOLOX→DINO：**5.1%**	**完成√**
跨断面识别匹配方法测试	系统跨断面匹配正确率达到 **95.8%**	**完成√**
集成加工具备识别与边缘处理能力的隧道交通感知样机	NPU加速下： YOLOX（960）：**95.44 ms** YOLOX（640）：**40.11 ms** ReID（256）：**35 ms**	**完成√**

3 隧道交通感知——模型训练

检测模型

指标	含义	YOLOX-S	DINO-swin
AP	全体目标平均精度	0.918	0.965
AP_S	小目标精度	0.984	0.987
AP_M	中目标精度	0.978	0.967
AP_L	大目标精度	0.904	0.969
T_{avg}	单张推理耗时（毫秒）	20.33	73.68
FPS	帧率	49.2	13.57

- ✓ 精度均达到**90%**以上；
- ✓ DINO精度高但效率很低，不适合用于追求实时性的工程应用。

yolo 特殊环境检测效果

dino 特殊环境检测效果

重识别模型

- mAP **0.717**，Rank-1 0.763，Rank-5 0.881，Rank-10 0.912。

3 隧道交通感知——系统搭建

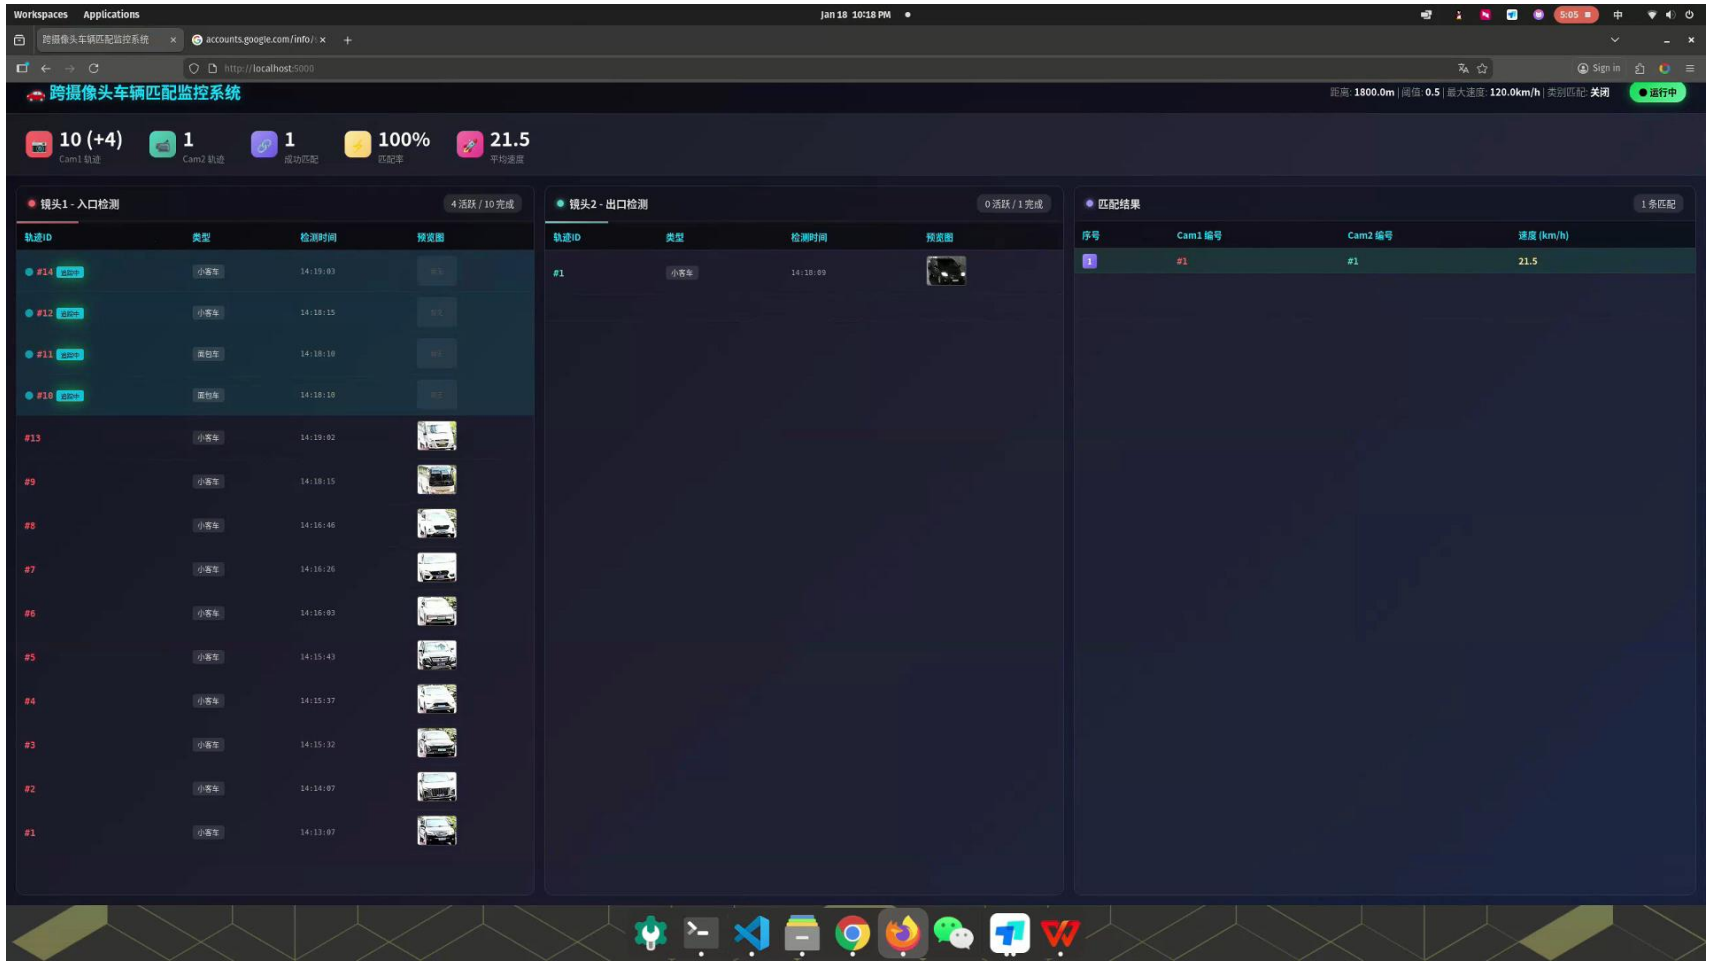

- 以 YOLOX-S 为检测引擎，ByteTrack 为跟踪核心，融合ReID 特征提取模型，集成端到端系统。
- 匹配正确率为 **95.8%**。

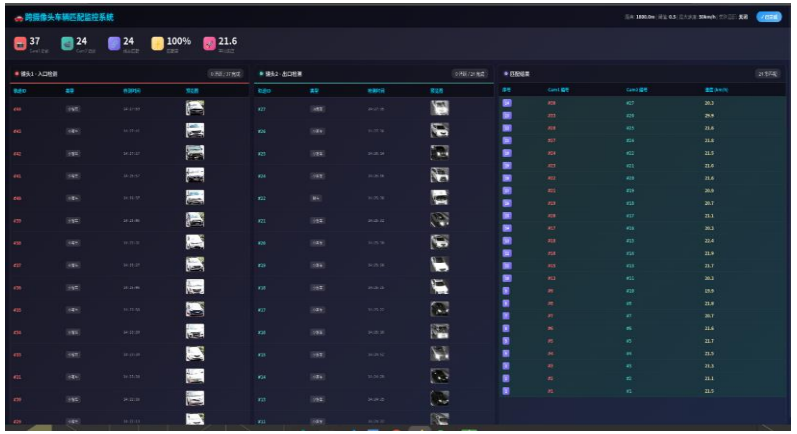

3 隧道交通感知——部署

模型	原始格式大小（MB）	ONNX 格式大小（MB）	ONNX 压缩率（%）	OM 格式大小（MB）	OM 压缩率(%)
YOLOX	79.1	35.8	54.7	18.0	77.2
DINO	378.3	190.8	49.5	-	-
ReID	181.2	178.8	1.3	86.5	51.6

模型	推理引擎	推理尺寸	处理速度（ms/图）	FPS	mAP
YOLOX	NVIDIA-3090	[1440,1440]	20.33	49.19	0.91
YOLOX	OrangePi-CPU	[1440,1440]	6741	0.15	0.83
YOLOX	OrangePi-NPU	[1440,1440]	184	5.43	0.83
YOLOX	OrangePi-NPU	[960,960]	85.44	11.7	0.81
YOLOX	OrangePi-NPU	[640,640]	40.11	24.93	0.78
ReID	NVIDIA-3090	[256,256]	5.75	173.91	0.76
ReID	OrangePi-CPU	[256,256]	16432	0.06	0.74
ReID	OrangePi-NPU	[256,256]	35	28.57	0.74

- **NPU加速计算速度**
  NPU展现出显著的加速效应（36倍、469倍），将模型从CPU运行的低效推向了工程可用，但性能仍然不如英伟达3090。

- **迁移精度掉点**
  从pth转换模型为om后，检测模型和reid模型精度均产生轻微损失，可接受范围内。

- **分辨率与实时性博弈**
  640尺寸虽达到25fps标准，但精度下降较多；960尺寸在效率和精度能相对保持较好的平衡。